

# 大连海事大学硕士研究生

## 学位论文中期进展报告

姓 名：王朝辉

学 号：1120231449

院（系）：信息科学技术学院

学 科：计算机技术

指导教师：翟华伟

论文题目：融合时空特征的图卷积网络  
交通流量预测方法研究

开题时间：2024 年 12 月 11 日

大连海事大学研究生院制

2019 年 1 月

## 硕士研究生中期进展报告填写说明及管理规定

一、3 年制研究生学位论文中期考核应于第 5 学期结束前完成；2 年制研究生学位论文中期考核应在开题通过半年后完成。

二、中期进展报告的内容与要求：

中期进展报告应逻辑严密、语句通顺、清晰易懂，图表格式规范。报告主要内容包括：

- （1）研究内容简介：简要说明开题报告中提出的工作设想和预期目标；
- （2）研究工作进展：说明是否按开题报告预定内容及进度进行，已完成的工作情况及取得的阶段性成果；
- （3）目前存在的主要问题和拟解决的途径；
- （4）下一步的工作计划：说明进度安排，论文预计完成时间，如期完成全部论文工作的可能性。

三、《硕士研究生中期进展报告》完成以后，应组织公开的中期考核报告会。

四、中期考核由学院负责统一组织，学科具体实施。中期考核小组由 3~5 名具有高级技术职称的专家组成，每个小组设组长和秘书各 1 名，小组中至少 3 人是硕士研究生导师，申请人的导师不能作为考核小组成员。考核专家主要依据硕士研究生的论文课题进展情况考核，同时参阅其课程学习和开题报告情况。中期考核结束后，考核专家应在本表中填写考核评价结果、评语和论文修改意见。

五、《硕士研究生中期进展报告》必须采用 A4 纸双面打印，左侧装订成册，各栏空格不够时，请自行加页。本表可在研究生院网站下载。

六、《硕士研究生中期进展报告》由学院留存。

论文题目	融合时空特征的图卷积网络交通流量预测方法研究
------	------------------------

<div>一、 研究内容简介</div> <p>本研究致力于提升交通流量预测的准确性，通过研究两种先进的深度学习交通流量预测方法——融合双重残差分解的多尺度动态图卷积网络交通流量预测和基于多尺度时空融合时滞模拟图卷积网络交通流量预测的方法，系统地解决交通流量预测中的关键问题。具体的研究内容如下：</p> <div>1 融合双重残差分解的多尺度动态图卷积网络交通流量预测方法</div> <p>针对交通预测领域中动态时空依赖捕捉不足与异常信号干扰两大核心挑战，提出了一种融合双重残差分解的多尺度动态图卷积网络交通流量预测方法MSDGDRD，为智能交通系统的精准流量预测提供了新的有效解决方案。</p> <p>首先，通过多尺度动态图生成模块（MSDG）构建了时空同步建模机制，将日尺度、周尺度的时间嵌入与空间嵌入深度融合，动态生成适配实时交通状态的图结构，有效突破了传统静态图模型难以刻画交通网络动态空间依赖的局限，充分利用了交通数据的时序趋势性与时空关联性。其次，设计的双重残差分解模块（DRD）基于自编码器与通道注意力机制，实现了正常交通信号与多类型异常信号（如事故、恶劣天气引发的扰动）的精准分离与独立建模，降低了异常信号对预测精度的干扰，提升了模型对复杂交通场景的适配能力。此外，动态图卷积递归模块（DGCRM）通过改进 GRU 结构，将动态图卷积与节点自适应学习相结合，进一步强化了时空特征的协同提取效果。</p> <div>2 基于多尺度时空融合时滞模拟图卷积网络交通流量预测方法</div> <p>为解决传统预测模型在刻画交通流数据复杂特性时的局限性，提出了一种新的时空交通流预测方法 MSTFDGCN。与传统模型不同，MSTFDGCN 创新性地同时考虑了交通流数据固有的时空相关性、异质性和传播延迟三大核心特征，通过独特的模块设计实现了多维度特征的精准建模。该模型引入自注意机制捕获全局时空相关性，借助多尺度时空延迟图卷积模块（M-STDGCM）模拟交通流变化的时滞效应并提取局部时空信息，再通过信息融合模块（IFM）动态整合全局与局部信息，有效弥补了传统模型或偏重局部、或忽视延迟的缺陷，显著增强了模型的预测性能。</p> <div>二、 研究工作进展</div> <div>1 融合双重残差分解的多尺度动态图卷积网络交通流量预测方法</div> <p>尽管交通预测领域很多研究工作已经取得显著进展，但是现有模型仍有两个方面的局限：第一个问题是交通系统之中位置之间的空间依赖性的高度动态的，而不是静态的，而且是随时间变化的，还会受到出行方式和意外事件的影响。然而现有的方法主要以静态方式包括预定义和自学习的方式对空间依赖进行建模，这限制了学</p>
--

习动态城市交通模式的能力，并且没有结合时空关系。为解决这个问题，本文提出了一种多尺度时空同步建模方式，将交通信息中的时间信息和空间信息转化为多尺度时空嵌入，再与从交通信号中提取的动态信号结合，动态构建交通流图结构。充分利用交通信息的时空相关性，并且多尺度的时间嵌入，包括日尺度、周尺度等信息，可以有效的利用交通数据的趋势性。

第二个问题是对异常信号的处理，交通状态是非线性的，且具有不确定性，受到交通事故等随机时间的干扰，交通信号具有一定的异常信号。目前的交通预测方法大都将所有交通信号视为平等关系，一起建模不加以区分，但是，异常信号不同于正常信号，异常信号会影响车辆轨迹、流量、速度等特征，将异常信号分离，挖掘异常信号的如何影响交通预测，会提高交通预测的精度。为解决这一问题，将利用自编码器逐层分离正常信号和多类型异常信号，并引入通道注意力机制，增强异常信号捕捉能力，分别通过独立的图卷积路径建模。通过将各个模块预测值融合，得到最终的预测结果。

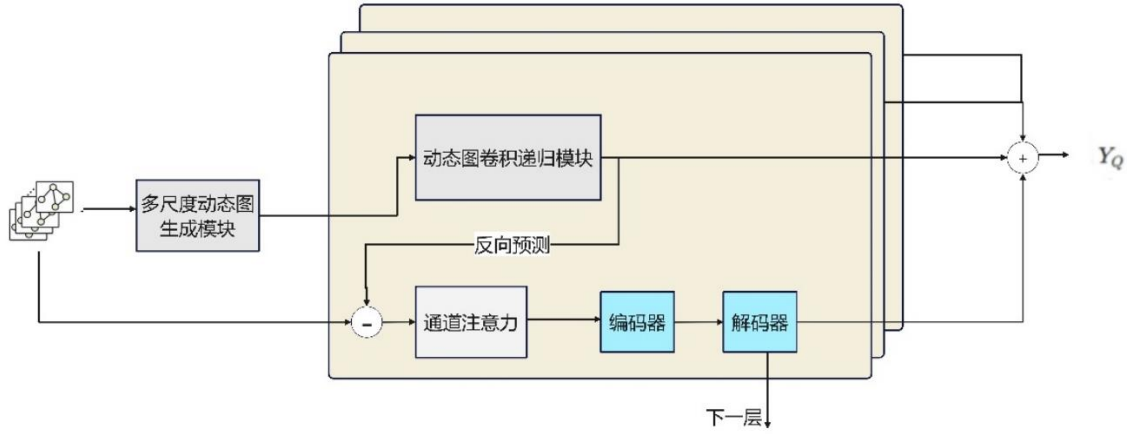


图 1.1 MSDGDRD 模型架构图

### 1.1 多尺度动态图生成模块

如图 1.2 所示，为了捕获道路网路的时空依赖性，利用时空嵌入生成器，找到与当前交通信号  $X_p$  对应的时间日嵌入  $T_p^D$  和周嵌入  $T_p^W$ 。然后用时间嵌入和空间嵌入分别进行逐元素乘积运算，从而获得对应的日时空嵌入  $E_p^D$  和周时空嵌入  $E_p^W$ ，三个元素的逐元素乘积得到总时空嵌入公式如下：

$$E_p^D = E \odot T_p^D \quad (1)$$

$$E_p^W = E \odot T_p^W \quad (2)$$

$$E_p^{st} = E \odot T_p^D \odot T_p^W \quad (3)$$

其中， $T_p^D, T_p^W \in R^{P \times N \times D}$  是由时间步长  $P = [t - P + 1, \dots, t]$  表示的每日嵌入和每周嵌入。 $\odot$  表示元素乘积运算。

在时间步长  $t$  中，当前时间步的输入通过  $MLP$  层，从而提取动态信号：

$$F_t = MLP(x_t) \quad (4)$$

其中， $F_t \in R^{N \times D}$  是滤波后得到的动态信号。然后对  $F_t$  和  $E_t^D$ 、 $E_t^W$ ，执行逐元素

乘法运算生成日动态图嵌入  $E_t^{d,D}$  和周动态图嵌入  $E_t^{d,W}$ ，表示如下：

$$E_t^{d,D} = \tan(F_t \odot E_t^D) \quad (5)$$

$$E_t^{d,W} = \tan(F_t \odot E_t^W) \quad (6)$$

然后，类似于节点相似性定义图，可以通过乘以  $E_t^{d,D}$  和  $(E_t^{d,D})^T$  来推断空间依赖性。

$$D_t^{-\frac{1}{2}} A_t^{d,D} D_t^{-\frac{1}{2}} = D_t^{-\frac{1}{2}} (\text{ReLU}(E_t^{d,D} (E_t^{d,D})^T)) D_t^{-\frac{1}{2}} \quad (7)$$

$$D_t^{-\frac{1}{2}} A_t^{d,W} D_t^{-\frac{1}{2}} = D_t^{-\frac{1}{2}} (\text{ReLU}(E_t^{d,W} (E_t^{d,W})^T)) D_t^{-\frac{1}{2}} \quad (8)$$

其中， $A_t^{d,D} \in R^{N \times N}$  表示时间步  $t$  处的日尺度动态图， $A_t^{d,W} \in R^{N \times N}$  表示时间步  $t$  处的周尺度动态图。

借助图注意力机制实现日、周动态图的融合。首先计算注意力权重：

$$\alpha_{i,j}^s = \frac{\exp(\text{LeakyReLU}(a^T | h_i^s | h_j^s |))}{\sum_{k \in N_i} \exp(\text{LeakyReLU}(a^T | h_i^s | h_k^s |))} \quad (9)$$

其中， $h_i^s$  表示尺度  $s$  ( $s \in \{D, W\}$ )，分别表示日尺度和周尺度下节点  $i$  的特征， $a^T$  是注意力参数， $N_i$  是  $i$  节点的邻居集合。

其次，对多尺度特征进行加权求和以更新节点特征：

$$h_i' = \sum_{s \in \{D, W\}} \sum_{j \in N_i} \alpha_{ij}^s W^s h_j^s \quad (10)$$

其中， $W^s$  是  $s$  对应的特征变换矩阵，通过此操作，学习日、周动态图中不同节点及尺度的重要性，实现多尺度特征图融合，最终输出融合够的动态图  $A_t^d$

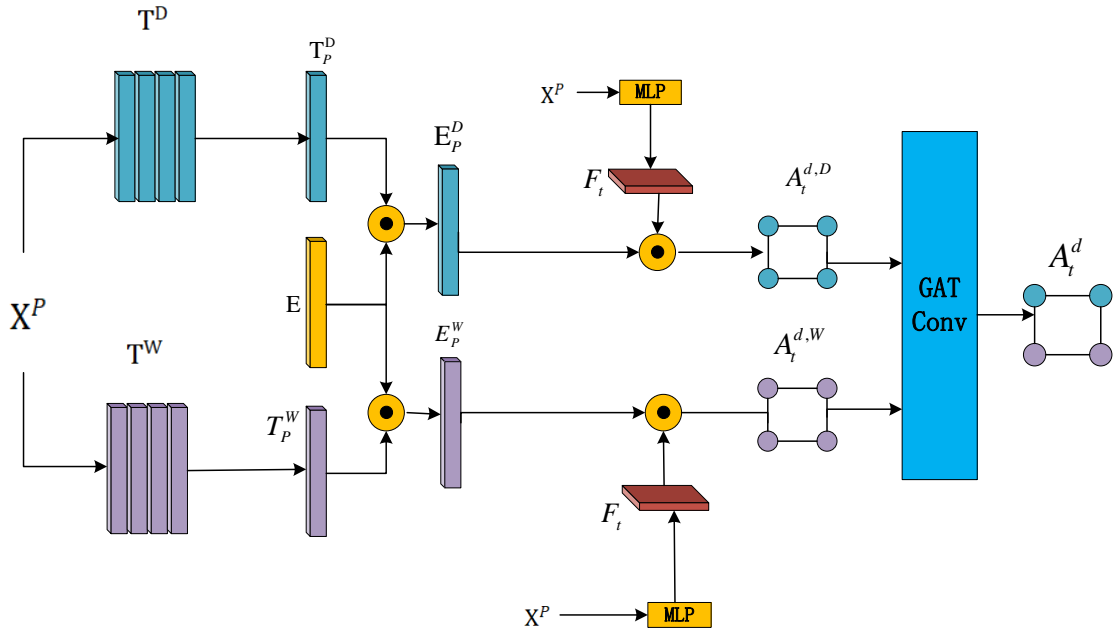


图 1.2 多尺度动态图生成模块图

### 1.2 动态图卷积递归模块

交通预测涉及复杂的时间相关性和空间相关性。在循环神经网络中，门控循环单元能有效捕捉时间和空间特征。通过将门控循环单元中的矩阵乘法替换成为动态

图卷积方法与 NAPL(节点自适应)模块的组合, 得到动态图卷积门控循环单元 (DGCRU), DGCRU 可表示为:

$$\begin{aligned}
r_t &= \sigma(\theta[x_t \parallel H_{t-1}, E_t^{st}]EW_r + Eb_r) \\
u_t &= \sigma(\theta[x_t \parallel H_{t-1}, E_t^{st}]EW_u + Eb_u) \\
\hat{h}_t &= \tanh(\theta[x_t \parallel r_t \odot H_{t-1}, E_t^{st}]EW_c + Eb_c) \\
H_t &= u_t \odot H_{t-1} + (1 - u_t) \odot \hat{h}_t
\end{aligned} \tag{11}$$

其中,  $x_t$  和  $H_t$  分别表示时刻  $t$  的输入输出,  $\sigma$  表示 *sigmoid* 激活函数,  $\theta$  表示动态图生成,  $\parallel$  表示拼接操作,  $W_r, W_u, W_c$  和  $b_r, b_u, b_c$  是可学习参数。

由 DGCRU 组成 DGCRM, 用于提取交通信号序列中的时空特征, 最后一个 DGCRU 的隐藏状态  $H_p$  作为 DGCRM 的输出  $H^l$ 。融合正常和异常信号的输出结果得到最终的预测结果。

### 1.3 双重残差分解模块

为实现信号分解加入一个线性层构成的输出子层, 处理正常信号和异常信号地方成分, 以实现更准确的预测。

#### 1.3.1 输出子层

输出子层有多个输出, 用于处理信号不同方面:

包括正常类信号的前向预测:  $y_l^f = \text{Linear}_{l,f}(H^l)$  和异常类信号的反向预测:  $x_b^l = \text{Linear}_{l,b}(H^l)$ 。其中,  $y_l^f$  表示第  $l$  个模块对信号的前向预测,  $x_b^l$  表示对第  $l$  个模块对信号的反向预测。

#### 1.3.2 通道注意力增强残差特征

在计算输入信号  $x_p^l$  与前向预测的正常类成分之间的残差前, 先对初步残差相关信号应用通道注意力机制。对于输入特征  $X \in R^{C \times H \times W}$  ( $C$  为通道数,  $H$ 、 $W$  为空间维度), 首先进行空间维度的全局平均池化与最大池化:

$$\begin{aligned}
\text{AvgPool}(X) &= \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_{i,j} \\
\text{MaxPool}(X) &= \max_{i,j} (X_{i,j})
\end{aligned} \tag{12}$$

定义多层感知机:

$$M(Z) = \sigma(W_2(\delta(W_1 Z))) \tag{13}$$

其中  $W_1$ 、 $W_2$  为卷积权重,  $\delta$  为 *ReLU* 激活函数,  $\sigma$  为 *sigmoid* 激活函数。由此生成通道权重  $A$ :

$$A = M(\text{AvgPool}(X) + \text{MaxPool}(X)) \tag{14}$$

最终, 通过逐元素相乘实现输入特征  $X$  的加权, 得到增强后地方特征  $X'$ 。

#### 1.3.3 信号分解与合并

计算输出信号  $x_p^l$  与前向预测正常类信号之间的残差

$$r^l = x_p^l - y_l^f \tag{15}$$

调整反向预测的异常成分, 将  $r^l$  输入异常信号检测模块, 首先利用自编码器结构对  $r^l$  压缩, 然后利用解码器将编码特征还原:

$$\begin{aligned}
E &= \text{ReLU}(W_2(\text{ReLU}(W_1 r^l + b_1)) + b_2) \\
D &= \text{ReLU}(W_4(\text{ReLU}(W_3 E + b_3)) + b_4)
\end{aligned} \tag{16}$$

其中,  $W_1, W_2, W_3, W_4$  为各层权重矩阵,  $b_1, b_2, b_3, b_4$  为偏置项。通过计算  $r^l$  与  $D$  的差异, 提取细化后的异常特征信息:

$$\Delta x_b^l = r^l - D \quad (17)$$

从而得出调整后的反向预测异常类成分:

$$x_b^{l'} = x_b^l + \Delta x_b^l \quad (18)$$

合并结果得到最终输出:

$$y = \sum_{l=1}^L y_l^f \quad (19)$$

$$x_p^{l+1} = x_p^l - x_b^{l'}$$

本方法利用多尺度动态图生成模块, 将日、周尺度的时间嵌入与空间嵌入深度融合并动态生成适配实时交通状态的图结构, 解决了传统静态图模型难以精准刻画交通网络动态空间依赖的问题; 借助双重残差分解模块, 基于级联自编码器与通道注意力机制实现正常交通信号和多类型异常信号的精准分离与独立建模, 解决了异常信号干扰预测精度、模型适配复杂交通场景能力不足的问题, 有效解决了交通预测领域动态时空依赖捕捉不足与异常信号干扰两大核心挑战。

## 2 基于多尺度时空融合时滞模拟图卷积网络交通流量预测方法

尽管融合双重残差分解的多尺度动态图卷积网络交通流量预测方法在图数据集上能有效提升预测精度, 可在基于网格的数据集上表现不够优越, 并且没有考虑到交通流传播延迟效应的问题, 为此提出了基于多尺度时空融合时滞模拟图卷积网络交通流量预测方法。

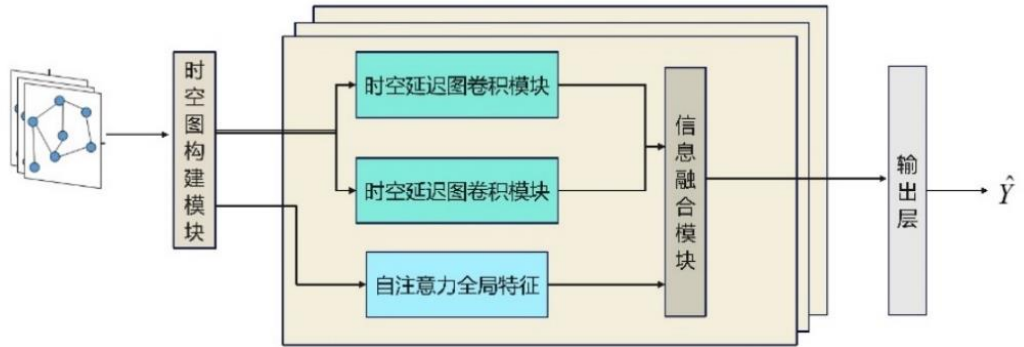


图 2.1 MSTFDGCN 整体框架图

### 2.1 多尺度局部时空图构建模块

针对交通流“日周期（早高峰 / 晚高峰）、周周期（工作日 / 周末）”的多尺度异质性, 构建适配不同尺度的局部时空图:

**多尺度滑动窗口:** 定义尺度集合  $S = \{s_1, s_2\}$ ,  $s_1$  为日尺度, 窗口大小  $T_1 = 12$  个时间步;  $s_2$  为周尺度, 窗口大小  $T_2 = 24$  个时间步, 对全局张量  $\tau$  进行滑动采样, 得到尺度  $s$  下的局部张量  $\tau^{(s)} \in R^{N \times C \times T_s}$  ( $C$  位特征维度,  $N$  为传感器数量)

**多尺度邻接矩阵:** 根据尺度  $s$  下的路网流量相关性, 动态调整邻接矩阵 (如日尺

度侧重短距离连通性，周尺度侧重长距离关联），得到  $A^{(s)} \in R^{3N \times 3N}$ （3 个连续时间步的节点拼接）：

$$A_{i,j}^{(s)} = \begin{cases} 1, & \text{节点 } i, j \text{ 在尺度 } s \text{ 下连通} \\ 0, & \text{否则} \end{cases} \quad (20)$$

多尺度时空嵌入：为增强尺度感知能力，设计可学习的时间嵌入  $T_{emb}^{(s)} \in R^{C \times T_s}$  和空间嵌入  $S_{emb}^{(s)} \in R^{N \times C}$ ，通过广播运算融合到局部张量：

$$\tau_{emb}^{(s)} = \tau^{(s)} + T_{emb}^{(s)} \oplus I_N + S_{emb}^{(s)} \oplus I_{T_s} \quad (21)$$

其中  $\oplus$  为广播操作， $I_N$  为  $N \times N$  单位矩阵。

### 2.2.2 自注意力全局特征提取模块

为捕捉跨区域的长程时空依赖（如全城拥堵传播），引入多尺度自注意力机制：线性变换生成  $Q$ 、 $K$ 、 $V$ ：对尺度  $s$  下的嵌入张量  $\tau_{emb}^{(s)}$ ，进行线性变换，生成查询（ $Q$ ）、键（ $K$ ）、值（ $V$ ）矩阵：

$Q^{(s)} = \tau_{emb}^{(s)} W_Q^{(s)}$ ， $K^{(s)} = \tau_{emb}^{(s)} W_K^{(s)}$ ， $V^{(s)} = \tau_{emb}^{(s)} W_V^{(s)}$ ，其中  $W_Q^{(s)}, W_K^{(s)}, W_V^{(s)} \in R^{C \times C'}$  为尺度  $s$  下的可学习权重矩阵， $C'$  为变换后特征维度。

多尺度注意力分数计算：通过点积计算注意力权重，并用  $\sqrt{d_k}$  ( $d_k = C'$ ) 归一化，避免梯度消失：

$$Attn^{(s)} = \text{Soft max}\left(\frac{Q^{(s)} \bullet (K^{(s)})^T}{\sqrt{d_k}}\right) \bullet V^{(s)} \quad (22)$$

输出尺度  $s$  下的全局特征：

$$G^{(s)} = Attn^{(s)} \in R^{N \times C' \times T_s} \quad (23)$$

### 2.2.3 多尺度时空延迟图卷积模块（M-STDGCM）

通过动态时滞步长适配多尺度交通流传播特性：

多尺度图卷积：基于尺度  $s$  下的邻接矩阵  $A^{(s)}$ ，对嵌入张量  $\tau_{emb}^{(s)}$  进行图卷积，捕捉局部空间依赖： $GConv^{(s)}(h^{(l-1)}) = \sigma(A^{(s)} h^{(l-1)} W_{gconv}^{(s)} + b_{gconv}^{(s)})$ ，其中  $h^{(l-1)} \in R^{3N \times C}$  为第  $l-1$  层输入， $W_{gconv}^{(s)} \in R^{C \times C'}$ 、 $b_{gconv}^{(s)} \in R^{C'}$  为可学习参数， $\sigma = GLU$  为激活函数（增强非线性表征）。

动态时滞模拟：根据尺度  $s$  设定时滞步长  $\Delta t^{(s)}$ （日尺度  $\Delta t^{(s_1)} = 1$ ，周尺度  $\Delta t^{(s_2)} = 3$ ），通过左右移位操作模拟交通流传播延迟：

$$S_{left}^{(s)}(h^l) = \text{Concat}[h_{\Delta t^{(s)}}^l, 0_{\Delta t^{(s)} \times N \times C}] \quad (24)$$

$$S_{right}^{(s)}(h^l) = \text{Concat}[0_{\Delta t^{(s)} \times N \times C}, h_{\Delta t^{(s)}}^l] \quad (25)$$

其中  $0$  为零张量， $h^l = GConv^{(s)}(h^{(l-1)})$  为图卷积输出。

时滞特征融合与聚合：融合移位特征与原始特征，通过最大池化聚合关键信息：



$$h_{de}^{(s,l)} = \frac{1}{3}(S_{left}^{(s)}(h^l) + h^l + S_{right}^{(s)}(h^l))h_{AGG}^{(s)} = \text{MaxPool}(h_{de}^{(s,l)}) \in R^{N \times C' \times T'_s} \quad (26)$$

其中  $T'_s$  为聚合后的时间维度,最后裁剪冗余时间步,仅保留中间时间步特征

$$L^{(s)} = h_{AGG}^{(s)}[:, :T'_s/2] \in R^{N \times C} \quad (27)$$

#### 2.2.4 信息融合模块 (IFM)

实现全局特征  $G^{(s)}$  与局部特征  $L^{(s)}$  的动态平衡:

全局特征池化: 对全局特征  $G^{(s)}$  进行时间维度池化, 适配局部特征维度:

$$G_{pool}^{(s)} = \text{maxPool}(G^{(s)}) \in R^{N \times C'} \quad (28)$$

门控融合机制: 通过门控权重  $g^{(s)}$  动态调节全局与局部特征的贡献度:

$$g^{(s)} = \text{sigmoid}(W_g^{(s)} \bullet \text{Concat}(G_{pool}^{(s)}, L^{(s)}) + b_g^{(s)}) \quad (29)$$

$$F_{fused}^{(s)} = g^{(s)} \odot G_{pool}^{(s)} + (1 - g^{(s)}) \odot L^{(s)} \quad (30)$$

其中  $W_g^{(s)} \in R^{2C \times C'}$ 、 $b_g^{(s)} \in R^{C'}$  为门控参数,  $\odot$  为元素乘法。

#### 2.2.5 模型输出与损失函数

多尺度特征拼接与映射: 拼接所有尺度的融合特征, 通过全连接层映射到预测维度:

$$F_{all} = \text{Concat}(F_{fused}^{(s1)}, F_{fused}^{(s2)}) \in R^{N \times 2C'} \quad (31)$$

$$\hat{Y} = \text{ReLU}(F_{all}W_1 + b_1)W_2 + b_2 \quad (32)$$

其中  $W_1 \in R^{2C' \times C''}$ 、 $W_2 \in R^{C'' \times T'}$  为全连接权重,  $C''$  为隐藏层维度,  $\hat{Y}$  为最终预测结果。

本方法利用多尺度局部时空图构建模块, 通过多尺度滑动窗口、动态邻接矩阵及时空嵌入, 解决了交通流日、周周期多尺度异质性难以适配建模的问题; 利用自注意力全局特征提取模块, 通过多尺度自注意力机制生成 Q、K、V 矩阵并计算注意力权重, 解决了跨区域长程时空依赖 (如全城拥堵传播) 难以捕捉的问题; 借助多尺度时空延迟图卷积模块, 通过动态时滞步长设定和移位操作, 解决了传统模型无法精准模拟交通流传播延迟效应的问题; 依托信息融合模块的门控融合机制, 解决了全局与局部特征贡献度失衡、无法动态平衡的问题, 最终弥补了传统预测模型难以同时刻画交通流时空相关性、异质性和传播延迟的缺陷。

### 3. 实验与分析

本文在四个真实公开的交通路网数据集上进行了大量实验, 验证所提方法的有效性。

#### 3.1 数据集

PEMS 系列数据集与加州高速公路交通流量有关, 由加州交通绩效测量系统 (PEMS) 以每 30s 的时间收集而来。原始的交通流量数据以 5 分钟为时间间隔, 并

且包含传感器之间的距离信息。数据从四个区域进行收集，汇总成为 PEMS03、PEMS04、PEMS07、PEMS08 四个数据集，在这四个数据集上进行实验，具体参数见表 3.1。

表 3.1 数据集介绍

Datasets	nodes	rate	Time steps	Time Range
PEMS03	358	26208	5min	2018.09-2018.11
PEMS04	307	16992	5min	2018.01-2018.02
PEMS07	883	28224	5min	2017.05-2017.08
PEMS08	170	17856	5min	2016.07-2016.08

### 3.2 实验设置

对于数据集采用 6:2:2 的比例分为训练集、验证集和测试集。对于模型的参数，将 DGCRU 模块的隐藏单元数目设置为 24，异常检测模块的压缩维度设置为 4，节点嵌入维度设置为 (12、22、16、10 分别对应 PEMS03、PEMS04、PEMS07、PEMS08)，对于训练设置，批大小设置为 64，初始学习率为 0.03，PEMS07 的初始学习率设置为 0.01。除了 PEMS07 数据集在 NVIDIA A100 Tensor Core GPU 上实现，其它数据集均在 NVIDIA GeForce GTX 3090 上实现。

### 3.3 对比实验

在四个数据集上测试了 MSDGDRD 和基线的性能，并检验了提前一个小时预测的平均误差，具体如表 3.2。MSDGDRD 在四个数据集上的预测性能均达到了最先进的水平。除此之外，我们还发现：（1）传统的预测方法如：VAR、ARIMA 预测性能相比于深度学习的方法要差很多，并且越是节点多的数据集，差距越明显。（2）FC-LSTM 等非基于图的模型虽然使用深度学习方法捕捉交通数据的时间特征，但是却忽略了空间相关性，因此表现并不好。当预测步长较长时，其长期时间相关性难以实现，因此总体性能相比 MSDGDRD 差很多。（3）STGCN、STSGCN 使用 GCN 捕捉空间相关性，然而用 GCN 和 CNN 捕捉时间相关性的表现并不好（4）基于 GNN 的方法，如 Z-GCNETS 和 AGCRN 通过自适应图捕捉隐藏的空间相关性，性能有所提升，但是其使用的自适应图是静态的，难以有效的解释。（5）ASTGCN、GMAN 和 DSTAGNN 都引入了注意力机制，但是注意力机制对于长期信息是敏感的，导致短期预测性能并不好，ASTGCN 虽然是时空注意力机制，但其表现并不如 GMAN 和 DSTAGNN。（6）MSSTAT 采用了一个平行的十字多头注意力，同步进行时空建模，然而其时空感知图仍不是动态的（7）DDGCRN 从传感器中提取动态信号、构建更适合的邻接矩阵。然而其没有对不同时间尺度的权重加以区分。

相比以上所有方法，MSDGDRD 采用多尺度动态图生成方式，既考虑构造动态图，又考虑到不同时间尺度的差异，在四个数据集上的表现都要更好。同时为了更好的观察 MSDGDRD 与基线模型在一个小时内的预测性能，绘制了图 3.1 和图 3.2 所示的 PEMS04 和 PEMS08 数据集的预测误差曲线。从图中可以明显看出，利用 MSDGDRD 预测的总体性能明显好于现有方法，且每个时间步的错误率也要更低。

表 3.2 不同模型在四个数据集上的性能比较

Models	PEMS03			PEMS04			PEMS07			PEMS08		
	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE	MAE	RMSE	MAPE
VAR	23.65	38.26	24.52%	24.54	38.61	17.24%	50.22	75.63	32.22%	19.19	29.81	13.10%
ARIMA	35.41	47.59	33.78%	33.73	48.80%	24.18%	38.17	59.27	19.46%	31.09	44.32	22.73%
FC-LSTM	21.33	35.11	23.33%	26.77	40.65	18.23%	29.98	45.94	13.20%	19.19	29.81	13.10%
STGCN	17.55	30.42	17.34%	21.16	34.89	13.83%	25.33	39.34	11.21%	17.50	27.09	11.29%
DCRNN	17.99	30.31	18.34%	21.22	33.44	14.17%	25.22	38.61	11.82%	16.82	26.36	10.92%
ASTGCN	17.34	29.56	17.21%	22.92	35.22	16.56%	24.01	37.87	10.73%	18.25	28.06	11.64%
STSGCN	17.48	29.21	16.78%	21.19	33.65	13.90%	24.26	39.03	10.21%	17.13	26.80	10.96%
AGCRN	15.98	28.25	15.23%	19.83	32.26	12.97%	22.37	36.55	9.12%	15.95	25.22	10.09%
Z-GCNETS	16.64	28.15	16.39%	19.50	31.61	12.78%	21.77	35.17	9.25%	15.76	25.11	10.01%
GMAN	15.52	26.53	15.19%	19.25	30.85	13.00%	20.68	33.56	9.31%	14.87	24.06	9.77%
DSTAGNN	15.57	27.21	14.68%	19.30	31.46	12.70%	21.42	34.51	9.01%	15.67	24.77	9.94%
MSSTAT	15.35	25.39	15.66%	18.57	30.37	12.23%	19.78	32.85	8.73%	<b>14.03</b>	23.44	9.34%
DDGCRN	14.63	25.07	14.22%	18.45	30.51	12.19%	19.79	33.11	8.35%	14.40	23.75	9.40%
MSDGDRD	<b>14.56</b>	<b>25.09</b>	<b>14.01%</b>	<b>18.37</b>	<b>30.14</b>	<b>12.10%</b>	<b>19.69</b>	<b>32.26</b>	<b>8.29%</b>	14.04	<b>22.88</b>	<b>9.15%</b>




图 3.1 PEMS04 上每个水平的预测性能比较




图 3.2 PEMS08 上每个水平的预测性能比较

### 3.4 消融实验

为了验证 MSDGDRD 各个组件的有效性，对 MSDGDRD 做以下消融实验。

w/o-DA: 仅使用日时空嵌入，去除周时空嵌入。

w/o-WE: 仅使用周时空嵌入，去除日时空嵌入。

w/o-GAT: 进行日、周尺度的普通时空嵌入融合, 去掉 GATConv 实现日、周动态图的融合步骤, 实现日、周嵌入逐元素乘法级融合。

w/o-DRD: 去除异常信号检测模块, 忽略异常信号的干扰, 将其视为平等信号直接建模。

实验结果见表 3.3:

表 3.3 消融实验对比

Dataset	Metric	w/o-DA	w/o-WE	w/o-GAT	w/o-DRD	MSDGDRD
PEMS04	MAE	19.12	18.50	18.70	18.68	18.37
	RMSE	32.41	30.75	30.83	30.91	30.14
	MAPE	12.58%	12.57%	12.17%	12.72%	12.10%
PEMS08	MAE	14.99	14.74	14.57	14.65	14.04
	RMSE	24.43	23.97	23.71	24.06	22.88
	MAPE	10.02%	9.54%	9.39%	10.03%	9.15%

为了更好的观察 MSDGDRD 与各种消融实验的对比效果, 绘制了如图 3.3、图 3.4 所示的 PEMS04 和 PEMS08 数据集的消融实验对比柱状图, 取 20min、40min 和平均的结果作对比柱状图。从图中可以明显看出, MSDGDRD 要低于各种消融实验结果, 从而证实各个组件都是有效的。




图 3.3 PEMS04 消融实验对比




图 3.4 PEMS08 消融实验对比

### 三、目前存在的主要问题和拟解决的途径

无主要问题，将按照计划完成论文工作。

### 四、下一步的工作计划（说明进度安排，论文预计完成时间，如期完成全部论文工作的可能性。）

日期	研究内容	预期成果
2025.12.12-2026.2.15	完成基于多尺度时空融合时滞模拟图卷积网络交通流量预测方法相关实验。	获取实验结果
2026.2.16-2026.3.15	撰写毕业论文	毕业论文初稿
2026.3.16-2026.3.31	修改毕业论文	毕业论文终稿

论文主要研究内容已经完成，实验将按照计划如期进行，能够按照计划如期完成论文工作。

### 五、指导教师评语

该论文主要研究融合时空特征的图卷积网络交通流量预测方法，提出了融合双重残差分解的多尺度动态图卷积网络交通流量预测和基于多尺度时空融合时滞模拟图卷积网络交通流量预测的方法，进行了真实世界主流交通数据集验证实验，撰写了论文主体内容，基本按照计划完成了论文主要研究工作，达到了中期检查要求。

签名：

日期： 年 月 日

六、中期考核结果（请在相应等级后的“（ ）”内打“√”，并给出评语和修改意见）

考核结论： 通过（ ）；不通过（ ）  
考核等级： 优秀（ ）；良 好（ ）； 一般（ ）； 不合格（ ）  
评语：

修改意见：

中期考核专家小组及秘书签名：  
组长\_\_\_\_\_   
成员\_\_\_\_\_   
秘书\_\_\_\_\_ 时间：\_\_\_\_\_ 年 \_\_\_\_\_ 月 \_\_\_\_\_ 日